

Endocrine AI: гормонально-модулируемый собеседник

Версия «стерва»

30 мая 2026 г.

Аннотация

Проект **Endocrine AI** объединяет детальную математическую модель эндокринной системы человека (гормоны, нейромедиаторы, менструальный цикл) и генеративную языковую модель для создания правдоподобного виртуального персонажа с переменчивым настроением. Текущая конфигурация реализует архетип «женщины-стервы»: она общается на русском языке, реагирует на тон собеседника, способна использовать ненормативную лексику, а её эмоциональное состояние зависит от уровня кортизола, серотонина, фазы менструального цикла и накопленной усталости. В статье описана архитектура системы, лежащая в её основе физиологическая модель, метод интеграции с языковой моделью и процедура дообучения для получения агрессивного речевого поведения.

1 Введение

Современные диалоговые агенты всё чаще наделяются элементами эмоционального интеллекта, однако их реакции обычно основаны на статичных правилах или обученных эмбедингах. Проект `endocrine_ai` предлагает принципиально иной подход: поведение персонажа управляется динамической симуляцией эндокринной системы человека. Изменения концентраций гормонов и нейромедиаторов, циркадные ритмы и фазы менструального цикла напрямую влияют на параметры генерации текста и тональность ответов. Это позволяет получить непредсказуемого, живого собеседника, чьё настроение эволюционирует во времени и зависит от истории общения.

В данной работе представлена версия «стерва» — персонаж с выраженной агрессивной, саркастичной и властной манерой речи, способный переходить от снисходительного похвалы к откровенной грубости в зависимости от внутреннего состояния и отношения к пользователю.

2 Архитектура системы

Система состоит из нескольких независимых модулей (рис. 1):

- `endocrine_model.py` — ядро, решающее систему обыкновенных дифференциальных уравнений (ОДУ) эндокринной динамики.

- `sentiment_analyzer.py` — анализ тональности входящего сообщения пользователя, извлекающий уровни стресса и комфорта.
- `dialogue_manager.py` — хранение и обрезка истории диалога.
- `bot.py` — главный класс, интегрирующий гормональную модель с генеративной языковой моделью и формирующий итоговый промпт.
- `main.py` — интерактивный чат-интерфейс командной строки.




Рис. 1: Функциональная схема взаимодействия модулей.

3 Математическая модель эндокринной системы

Файл `endocrine_model.py` содержит описание динамики основных гормональных осей. Все концентрации нормированы на диапазон $[0, 1]$, где 1 соответствует верхней границе физиологической нормы. Модель решается методом Эйлера с шагом $\Delta t = 0.1$ минуты.

3.1 Переменные состояния

Ключевые переменные:

- Гипоталамо-гипофизарно-надпочечниковая ось (стресс): `cortisol` (кортизол), `crh`, `acth`, `crh_delayed`, `acth_delayed`.
- Нейромедиаторы: `serotonin`, `dopamine`, `noradrenaline`, `oxytocin`.
- Метаболическая ось: `t3`, `glucose`, `insulin`.
- Гонадная ось (женский цикл): `gnrh`, `lh`, `estradiol`, `progesterone`.

- Адаптивные параметры: `gr_sensitivity` (чувствительность глюкокортикоидных рецепторов), `ht1a_sensitivity` (чувствительность серотониновых 5-HT1A-ауторецепторов), `allostatic_load` (аллостатическая нагрузка).
- Социальная переменная: `user_respect` (уважение к собеседнику) $\in [0, 1]$.

3.2 Нелинейные функции активации/ингибирования

Взаимодействия между гормонами описываются сигмоидными функциями Хилла:

$$\text{hill_activation}(x, K, n) = \frac{x^n}{K^n + x^n}, \quad (1)$$

$$\text{hill_inhibition}(x, K, n) = \frac{K^n}{K^n + x^n}, \quad (2)$$

где K — точка полунасыщения, n — коэффициент кооперативности (крутизна).

3.3 Пример: ось кортизола

Динамика кортиколиберина (CRH) и кортизола описывается следующими уравнениями:

$$\frac{d \text{crh}}{dt} = (0.4 \text{stress} + 0.15 \text{allostatic_load}) \cdot \text{hill_inhibition}(\text{cortisol}, 0.5, 3) \cdot \text{gr_sensitivity} - 0.2 \text{crh} \quad (3)$$

$$\frac{d \text{crh_del}}{dt} = \frac{\text{crh} - \text{crh_delayed}}{5.0}, \quad (4)$$

$$\frac{d \text{acth}}{dt} = (0.6 \text{crh_delayed}) \cdot \text{hill_inhibition}(\text{cortisol}, 0.5, 2) \cdot \text{gr_sensitivity} - 0.25 \text{acth}, \quad (5)$$

$$\frac{d \text{cortisol}}{dt} = 0.3 \text{acth_delayed} + \text{circadian_cortisol}(t) - 0.15 \text{cortisol}. \quad (6)$$

Аналогичные системы связывают остальные оси: серотониновую (с учётом 5-HT1A-ауторецепторов), дофаминовую, тиреоидную и гонадную.

3.4 Циркадные ритмы

Фаза суток $\phi = t_{\text{sim}}/1440$ (минуты). Для кортизола задана синусоидальная модуляция с пиком утром (≈ 8 ч) и дневным подъёмом:

$$\text{circadian_cortisol}(\phi) = 0.05 + 0.2 \max(\sin(2\pi(\phi - 0.33)), 0.1 \sin(2\pi(\phi - 0.66))). \quad (7)$$

Серотонин выше днём, тиреоидный гормон снижается ночью.

3.5 Менструальный цикл

Для женской конфигурации (`SEX = "female"`) моделируется 28-дневный цикл. Фаза $\psi = (\phi \cdot 24/28) \bmod 1$ определяет:

- 0.0–0.14: менструация;

- ≈ 0.5 : овуляция (пик ЛГ, затем рост прогестерона);
- 0.57–0.9: лютеиновая фаза и ПМС.

В лютеиновой фазе вводится фактор `pms_factor`, усиливающий подавление серотонина:

$$\text{pms_factor}(\psi) = 1.5 + 0.5 \sin\left(2\pi \frac{\psi - 0.5}{0.4}\right), \quad \psi \in [0.5, 0.9]. \quad (8)$$

Синтез серотонина делится на этот фактор, что вызывает раздражительность и агрессивность в предменструальный период.

3.6 Внешние сигналы и уважение

Анализатор тональности преобразует текст пользователя в два числа: `stress` $\in [0, 1]$ (негатив, грубость) и `comfort` $\in [0, 1]$ (позитив, поддержка). Они поступают на вход эндокринной модели и изменяют `user_respect`:

$$\Delta \text{respect} = (\text{comfort} \cdot 1.0 + \text{stress} \cdot (-1.5)) \cdot \text{RESPECT_CHANGE_RATE}, \quad (9)$$

после чего значение ограничивается в $[0, 1]$. Отрицательный коэффициент при стрессе ускоряет потерю уважения.

4 Интеграция с языковой моделью

Класс `EndocrineConversationalBot` объединяет гормональную модель с генеративной LLM (по умолчанию `ai-forever/rugpt3small`).

4.1 Влияние гормонов на генерацию

Параметры сэмплирования модифицируются состоянием:

$$\text{temperature} = \text{base_temp} + \text{dopamine} \cdot 0.3 + \text{noradrenaline} \cdot 0.05 + (1 - \text{user_respect}) \cdot 0.3, \quad (10)$$

$$\text{top_p} \propto 1 - 0.2 \text{serotonin}. \quad (11)$$

Высокий дофамин и норадреналин, а также низкое уважение делают ответы более хаотичными и непредсказуемыми.

4.2 Системный промпт

В промпт включается физиологический статус (фаза цикла, уровни тревожности/раздражения) и инструкция по тону, зависящая от `user_respect`:

- < 0.3 : крайняя грубость, мат, команды, унижения.
- 0.3–0.6: сарказм, пренебрежение, допустим лёгкий мат.
- ≥ 0.6 : снисходительный, властный тон, ирония без мата.

4.3 Дообучение для характера «стерва»

Базовая модель RuGPT3 обучена на литературных текстах и избегает обценной лексики. Для усиления агрессивного речевого поведения используется скрипт `fine_tune.py`. Данные собираются транскрибацией аудио с помощью Whisper (`transcribe.py`) в файл `data/transcripts.json`. Каждая реплика (монолог) становится тренировочным примером. Модель дообучается 3 эпохи с `causal language modeling objective`.

После дообучения модель заменяется на `./fine_tuned_sterfa`, что радикально повышает частоту и естественность матерной речи.

5 Пример диалога

Ниже приведён фрагмент взаимодействия с версией «стерва» (фаза ПМС, низкое уважение):

```
1 User: , ?
2 Bot: [ 0.8, 0.2,
        0.2]
3
4 User: ?
5 Bot: ,
```

6 Заключение

Проект `endocrine_ai` демонстрирует, как биофизическая симуляция может управлять речевым поведением виртуального персонажа. Физиологическая достоверность (гормональные оси, циклы, рецепторная адаптация) открывает возможности для аффективных вычислений, игровых NPC и психологических экспериментов. Модульная архитектура позволяет легко заменять языковые модели и добавлять новые гормональные контуры.

Будущие направления включают более точную модель мужской физиологии, интеграцию с голосовым синтезом и расширение набора архетипов личности.